Inteligência Computacional – 2023/24

Projeto – Fase1

Elementos do grupo:

Luís Henrique P. O. Travassos, nº2021136600

Rodrigo Ramalho Ferreira, nº2021139149

Conteúdo:

1. Descrição do caso de estudo e objetivos do problema

O projeto aborda a classificação de imagens de ruas em três categorias: ruas limpas, ruas sujas e ruas com ecopontos. Isto é crucial para monitorar e promover a conscientização sobre a limpeza e sustentabilidade urbana, contribuindo para o desenvolvimento sustentável das cidades.

Classificação precisa: O principal objetivo é desenvolver um modelo de machine learning capaz de classificar com alta precisão as imagens de ruas nas três categorias especificadas.

Conscientização e Monitoramento: A classificação precisa permitirá um monitoramento eficaz do estado das ruas em relação à limpeza e presença de ecopontos. Isso pode ser usado para criar campanhas de conscientização e melhorar a gestão urbana.

Uso de Dados Disponíveis: Com um dataset de 5400 fotos, aproximadamente 1800 por categoria, será possível treinar um modelo robusto que pode generalizar bem para novas imagens.

Avaliação e Iteração: Será usado o Perceptron Multicamadas (MLP) como implementação para aprendizado e avaliação.

Aprimoramento Contínuo: Com base nos resultados iniciais, serão feitos ajustes na arquitetura da rede neural e nos parâmetros de treinamento para melhorar a performance.

Avaliação de Métricas: Métricas como precisão, sensibilidade, especificidade, f-measure e área sob a curva ROC serão utilizadas para quantificar o desempenho do modelo em relação às três categorias de imagens.

Aplicação Futura: Além do escopo inicial, o modelo poderá ser aplicado em um contexto mais amplo de monitoramento urbano e tomada de decisões relacionadas à gestão sustentável das cidades.

O projeto visa contribuir para a melhoria do ambiente urbano, promovendo a conscientização e ação em prol da sustentabilidade e limpeza das ruas. Também servirá como uma base sólida para futuras iterações e aprimoramentos na abordagem de classificação de imagens.

2. Descrição da implementação dos algoritmos

O código apresentado realiza a implementação de um sistema de classificação de imagens utilizando técnicas de aprendizado de máquina e redes neurais utilizando a biblioteca TensorFlow e suas extensões. Abaixo, segue uma descrição detalhada do código:

Importação de Bibliotecas: O código começa com a importação de diversas bibliotecas essenciais para a execução do programa. Cada uma dessas bibliotecas oferece funcionalidades específicas para diferentes etapas do processo.

```
# Importando as bibliotecas necessárias
from sklearn.preprocessing import LabelEncoder, OneHotEncoder  # Para pré-processamento de dados
from sklearn.utils import shuffle  # Para embaralhar os dados
from sklearn.model_selection import train_test_split  # Para dividir o conjunto de dados em treinamento e teste
from sklearn.metrics import (  # Métricas de avaliação de modelo
    confusion_matrix, accuracy_score, recall_score, f1_score, roc_auc_score, classification_report
)

from tensorflow.keras.optimizers import Adam  # Otimizador para a rede neural
from tensorflow.keras.preprocessing.image import load_img, img_to_array  # Pré-processamento de imagens

import keras  # Biblioteca Keras para criação de modelos de redes neurais
import tensorflow as tf  # TensorFlow para construção de redes neurais

import matplotlib.pyplot as plt  # Para plotagem de gráficos
import pandas as pd  # Manipulação de dados em formato tabular
import numpy as np  # Biblioteca NumPy para manipulação de matrizes
import cv2  # OpenCV para processamento de imagens
import os  # Operações com sistema de arquivos
```

Definição do Diretório, tamanho das Imagens e listagem dos Tipos de Ruas: A variável path é definida como 'Dataset2/', indicando o caminho onde os dados (imagens) estão armazenados. Além disso, im_size é definido como 350, indicando a dimensão em pixels que as imagens serão redimensionadas. A função os.listdir(path) é usada para obter uma lista de todos os arquivos e diretórios dentro do caminho especificado, isto é, os diferentes tipos de ruas(limpas, sujas, com ecopontos). O resultado é armazenado na variável street_types.

```
path = 'Dataset2/'  # Definindo o caminho do diretório contendo o dataset
im_size = 350  # Definindo o tamanho desejado para as imagens

street_types = os.listdir(path)  # Listando os tipos de ruas disponíveis no diretório
print(street_types)  # Imprimindo os tipos de ruas encontrados
print("Tipos de ruas encontrados: ", len(street_types))  # Imprimindo o número de tipos de ruas encontrados
```

```
['clean', 'litter', 'recycle']
Tipos de ruas encontrados:  3
```

Organizar e estruturar os dados de imagens: Este trecho de código percorre os diferentes tipos de ruas, armazena os nomes dos arquivos de imagem associados a cada tipo e os organiza em um DataFrame para facilitar o acesso e manipulação dos dados.

```
streets = []  # Lista vazia para armazenar informações das ruas

# Iterando sobre os diferentes tipos de ruas
for item in street_types:
    all_streets = os.listdir(path + '/' + item)  # Obtendo todos os nomes de arquivo na pasta

    # Adicionando os nomes de arquivo à lista 'streets'
    for street in all_streets:
        streets.append((item, str(path + '/' + item) + '/' + street))

# Criando um DataFrame do pandas com as informações das ruas
streets_df = pd.DataFrame(data=streets, columns=['street type', 'image'])
```

Verificação de ficheiros no dataset: Este código fornece um resumo estatístico das quantidades de imagens em cada categoria de rua presente no conjunto de dados. É uma forma rápida de verificar a distribuição das classes.

```
# Imprimindo o número total de ruas no conjunto de dados
print("Total number of streets in the Dataset: ", len(streets_df))

# Contando o número de ruas em cada categoria e imprimindo os resultados
street_count = streets_df['street type'].value_counts()
print("Ruas em cada categoria: ")
print(street_count)
```

```
Total number of streets in the Dataset:  5405
Ruas em cada categoria:
street type
recycle    1875
clean      1825
litter     1705
Name: count, dtype: int64
```

Carregamento e pré-processamento das imagens do conjunto de dados: Este código carrega e pré-processa as imagens do conjunto de dados, convertendo-as em arrays numpy e normalizando os valores dos pixels. As imagens são armazenadas em imagens e suas etiquetas correspondentes em labels.

```
images = []  # Lista para armazenar as imagens
labels = []  # Lista para armazenar as etiquetas das ruas

# Iterando sobre os diferentes tipos de ruas
for label in street_types:
    data_path = os.path.join(path, label)  # Obtendo o caminho para os dados de uma categoria
    filenames = os.listdir(data_path)  # Obtendo os nomes dos arquivos de imagem na categoria

    # Iterando sobre os arquivos de imagem na categoria
    for filename in filenames:
        img_path = os.path.join(data_path, filename)  # Obtendo o caminho completo da imagem
        img = load_img(img_path, target_size=(im_size, im_size))  # Carregando a imagem e redimensionando
        img_array = img_to_array(img)  # Convertendo a imagem para um array numpy
        images.append(img_array)  # Adicionando a imagem à lista de imagens
        labels.append(label)  # Adicionando a etiqueta da rua à lista de etiquetas

# Convertendo a lista de imagens para um array numpy e normalizando os valores de pixel
images = np.array(images)
images = images.astype('float32') / 255.0

# Obtendo a forma (shape) do array de imagens
images.shape
```

```
]: (5405, 350, 350, 3)
```

Preparação dos dados para treinamento e teste do modelo de classificação: Este código prepara os dados para treinamento e teste do modelo de classificação. As imagens estão em train_x e test_x, enquanto suas etiquetas correspondentes estão em train_y e test_y. Isso permite que o modelo seja treinado e avaliado de forma apropriada.

```
# Obtendo as etiquetas das ruas do DataFrame
y = streets_df['street type'].values

# Convertendo as etiquetas para valores numéricos usando LabelEncoder
y_labelenconder = LabelEncoder()
y = y_labelenconder.fit_transform(y)

# Embaralhando as imagens e suas etiquetas para garantir uma mistura aleatória
images, y = shuffle(images, y, random_state=1)

# Dividindo os dados em conjuntos de treinamento e teste
train_x, test_x, train_y, test_y = train_test_split(images, y, test_size=0.05, random_state=415)

# Imprimindo as formas (shapes) dos conjuntos de dados
print(train_x.shape)
print(test_x.shape)
print(train_y.shape)
print(test_y.shape)
```

```
(5134, 350, 350, 3)
(271, 350, 350, 3)
(5134,)
(271,)
```

Definição, treinamento e avaliação do modelo de rede neural: Este código define, treina e avalia um modelo de rede neural para a classificação de imagens. O modelo é construído com camadas densas e treinado usando o optimizador Adam. As previsões são geradas para o conjunto de teste.

```
# Definindo o modelo da rede neural
model = keras.Sequential([
    keras.layers.Flatten(input_shape=(im_size, im_size, 3)),  # Camada de achatamento para transformar a imagem em vetor
    keras.layers.Dense(256, activation=tf.nn.tanh),  # Camada densa com ativação tangente hiperbólica
    keras.layers.Dense(128, activation=tf.nn.relu),   # Camada densa adicional com ativação ReLU
    keras.layers.Dense(64, activation=tf.nn.relu),    # Outra camada densa adicional com ativação ReLU
    keras.layers.Dense(3, activation=tf.nn.softmax)   # Camada de saída com ativação softmax (3 classes)
])

# Compilando o modelo
model.compile(optimizer=Adam(learning_rate=0.01),
              loss='sparse_categorical_crossentropy',  # Função de perda para classificação multiclasse
              metrics=['accuracy'])  # Métrica de avaliação

# Treinando o modelo
model.fit(train_x,
          train_y,
          epochs=10,  # Número de épocas de treinamento
          batch_size=64,  # Tamanho do lote
          validation_data=(test_x, test_y))  # Dados de validação

# Obtendo as probabilidades de classe previstas
y_probs = model.predict(test_x)

# Obtendo as previsões finais (índices da classe com a maior probabilidade)
y_pred = np.argmax(y_probs, axis=1)
```

Avaliação do desempenho do modelo: Este código gera uma série de métricas de avaliação para o modelo, incluindo a matriz de confusão, um relatório de classificação e a AUC para cada classe. Essas métricas fornecem uma visão abrangente do desempenho do modelo em relação às diferentes classes de ruas.

```
# Calculando a matriz de confusão
confusion = confusion_matrix(test_y, y_pred)
print("Matriz de Confusão:")
print(confusion)

# Gerando um relatório de classificação
report = classification_report(test_y, y_pred, target_names=street_types, zero_division=1)
print(report)

# Calculando a Área sob a Curva (AUC) para cada classe
for i in range(len(street_types)):
    auc = roc_auc_score(test_y == i, y_probs[:, i])
    print(f"AUC para classe {street_types[i]}: {auc}")
```

3. Análise de resultados

3.1. Dataset normal com modelo de dados MLP (melhor resultado)

O conjunto de dados original para este problema consiste em 5405 fotos, todas com dimensões variadas. É necessário redimensioná-las no código para garantir uniformidade. Cada uma das três classes - ruas limpas, sujas e com ecopontos - contém aproximadamente 1800 fotos, todas apresentando certo nível de complexidade. Abaixo estão alguns exemplos:

Rua Limpa	Rua Suja	Rua com Ecopontos
	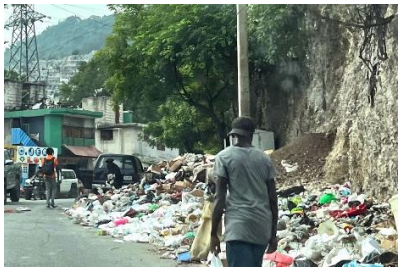	

A configuração do modelo MLP usada:

```
# Definindo o modelo da rede neural
model = keras.Sequential([
    keras.layers.Flatten(input_shape=(im_size, im_size, 3)),
    keras.layers.Dense(1024, activation=tf.nn.relu),
    keras.layers.Dense(512, activation=tf.nn.relu),
    keras.layers.Dense(256, activation=tf.nn.relu),
    #keras.layers.Dense(128, activation=tf.nn.relu),
    #keras.layers.Dense(64, activation=tf.nn.relu),
    #keras.layers.Dense(32, activation=tf.nn.relu),
    keras.layers.Dense(3, activation=tf.nn.softmax)
])

# Compilando o modelo
model.compile(optimizer=Adam(learning_rate=0.009),
              loss='sparse_categorical_crossentropy',  # Função de perda para classificação multiclasse
              metrics=['accuracy'])  # Métrica de avaliação
```

Resultados obtidos:

```
Matriz de Confusão:
[[75 19  4]
 [15 53  6]
 [10 15 74]]
              precision    recall  f1-score   support

       clean       0.75      0.77      0.76        98
      litter       0.61      0.72      0.66        74
     recycle       0.88      0.75      0.81        99

    accuracy                           0.75       271
   macro avg       0.75      0.74      0.74       271
weighted avg       0.76      0.75      0.75       271

AUC para classe clean: 0.8976052848885219
AUC para classe litter: 0.8656880230484291
AUC para classe recycle: 0.9168428470754052
```

Analisando estes resultados, é possível verificar que o desempenho do modelo é consideravelmente satisfatório, mas longe de excelente, tendo em conta que a complexidade do conjunto de dados é alta. De seguida iremos analisar os outros casos.

3.2. Dataset normal com modelo de dados MLP (mais camadas)

Para esta análise iremos alterar o modelo de dados MLP de forma a ele possuir mais camadas, sem afetar muito o número de neurónios, para observar que tipo de resultados podemos obter.

A configuração do modelo MLP usada:

```
# Definindo o modelo da rede neural
model = keras.Sequential([
    keras.layers.Flatten(input_shape=(im_size, im_size, 3)),
    keras.layers.Dense(1024, activation=tf.nn.relu),
    keras.layers.Dense(512, activation=tf.nn.relu),
    keras.layers.Dense(256, activation=tf.nn.relu),
    keras.layers.Dense(128, activation=tf.nn.relu),
    #keras.layers.Dense(64, activation=tf.nn.relu),
    #keras.layers.Dense(32, activation=tf.nn.relu),
    keras.layers.Dense(3, activation=tf.nn.softmax)
])

# Compilando o modelo
model.compile(optimizer=Adam(learning_rate=0.009),
              loss='sparse_categorical_crossentropy',  # Função de p
              metrics=['accuracy'])  # Métrica de avaliação
```

Resultados obtidos:

```
Matriz de Confusão:
[[47 48  3]
 [ 9 55 10]
 [ 3 32 64]]
              precision    recall  f1-score   support

       clean       0.80      0.48      0.60        98
      litter       0.41      0.74      0.53        74
     recycle       0.83      0.65      0.73        99

    accuracy                           0.61       271
   macro avg       0.68      0.62      0.62       271
weighted avg       0.70      0.61      0.63       271

AUC para classe clean: 0.8589123510675946
AUC para classe litter: 0.7231444642612156
AUC para classe recycle: 0.872093023255814
```

Analisando estes resultados, a configuração com mais camadas não parece ser uma melhoria em relação à melhor configuração. Parece que, ao adicionar mais camadas, o modelo pode ter se tornado mais complexo e pode estar sofrendo de overfitting ou dificuldades em generalizar para novos dados.

A configuração com mais camadas teve uma melhora na precisão da classe "clean", mas um desempenho significativamente pior para as classes "litter" e "recycle". A precisão geral do modelo (acurácia) também diminuiu, indicando que a configuração com mais camadas não é tão eficaz em geral.

3.3. Dataset normal com modelo de dados MLP (menos camadas)

Para esta análise iremos alterar o modelo de dados MLP de forma a ele possuir menos camadas, sem afetar muito o número de neurónios, para observar que tipo de resultados podemos obter.

A configuração do modelo MLP usada:

```
# Definindo o modelo da rede neural
model = keras.Sequential([
    keras.layers.Flatten(input_shape=(im_size, im_size, 3)),
    keras.layers.Dense(1024, activation=tf.nn.relu),
    keras.layers.Dense(512, activation=tf.nn.relu),
    #keras.layers.Dense(256, activation=tf.nn.relu),
    #keras.layers.Dense(128, activation=tf.nn.relu),
    #keras.layers.Dense(64, activation=tf.nn.relu),
    #keras.layers.Dense(32, activation=tf.nn.relu),
    keras.layers.Dense(3, activation=tf.nn.softmax)
])

# Compilando o modelo
model.compile(optimizer=Adam(learning_rate=0.009),
              loss='sparse_categorical_crossentropy',  # Função de perda para classificação multiclasse
              metrics=['accuracy'])  # Métrica de avaliação
```

Resultados obtidos:

```
Matriz de Confusão:
[[98  0  0]
 [74  0  0]
 [99  0  0]]
              precision    recall  f1-score   support

       clean       0.36      1.00      0.53        98
      litter       1.00      0.00      0.00        74
     recycle       1.00      0.00      0.00        99

    accuracy                           0.36       271
   macro avg       0.79      0.33      0.18       271
weighted avg       0.77      0.36      0.19       271

AUC para classe clean: 0.5037454288073611
AUC para classe litter: 0.4915283303608177
AUC para classe recycle: 0.5035236081747709
```

Relativamente a estes resultados, a configuração com menos camadas apresenta um desempenho muito pior em comparação com a melhor configuração. Na verdade, não está conseguindo aprender corretamente as características das classes "litter" e "recycle", resultando em uma classificação praticamente ineficaz.

3.4. Dataset normal com modelo de dados MLP (mais neurónios)

Para esta análise iremos alterar o modelo de dados MLP de forma a ele possuir mais neurónios, sem afetar o número de camadas, para observar que tipo de resultados podemos obter.

A configuração do modelo MLP usada:

```
# Definindo o modelo da rede neural
model = keras.Sequential([
    keras.layers.Flatten(input_shape=(im_size, im_size, 3)),
    keras.layers.Dense(2048, activation=tf.nn.relu),
    keras.layers.Dense(512, activation=tf.nn.relu),
    keras.layers.Dense(256, activation=tf.nn.relu),
    #keras.layers.Dense(128, activation=tf.nn.relu),
    #keras.layers.Dense(64, activation=tf.nn.relu),
    #keras.layers.Dense(32, activation=tf.nn.relu),
    keras.layers.Dense(3, activation=tf.nn.softmax)
])

# Compilando o modelo
model.compile(optimizer=Adam(learning_rate=0.009),
              loss='sparse_categorical_crossentropy',  # Função de perda para classificação multiclasse
              metrics=['accuracy'])  # Métrica de avaliação
```

Resultados obtidos:

```
Matriz de Confusão:
[[98  0  0]
 [74  0  0]
 [99  0  0]]
              precision    recall  f1-score   support

       clean       0.36      1.00      0.53        98
      litter       1.00      0.00      0.00        74
     recycle       1.00      0.00      0.00        99

    accuracy                           0.36       271
   macro avg       0.79      0.33      0.18       271
weighted avg       0.77      0.36      0.19       271

AUC para classe clean: 0.5037454288073611
AUC para classe litter: 0.4915283303608177
AUC para classe recycle: 0.5035236081747709
```

Relativamente a estes resultados parece que simplesmente aumentar o número de neurónios não está sendo eficaz para melhorar o desempenho do modelo.

A configuração com mais neurônios possui desempenho semelhante à configuração com menos camadas. O modelo continua a classificar a maioria das instâncias como "clean", ignorando completamente as outras classes ("litter" e "recycle").

As métricas de precisão, recall e f1-score para as classes "litter" e "recycle" permanecem extremamente baixas, indicando uma incapacidade de aprender corretamente essas classes.

3.5. Dataset normal com modelo de dados MLP (menos neurónios)

Para esta análise iremos alterar o modelo de dados MLP de forma a ele possuir menos neurónios, sem afetar o número de camadas, para observar que tipo de resultados podemos obter.

A configuração do modelo MLP usada:

```
# Definindo o modelo da rede neural
model = keras.Sequential([
    keras.layers.Flatten(input_shape=(im_size, im_size, 3)),
    keras.layers.Dense(512, activation=tf.nn.relu),
    keras.layers.Dense(256, activation=tf.nn.relu),
    keras.layers.Dense(128, activation=tf.nn.relu),
    #keras.layers.Dense(128, activation=tf.nn.relu),
    #keras.layers.Dense(64, activation=tf.nn.relu),
    #keras.layers.Dense(32, activation=tf.nn.relu),
    keras.layers.Dense(3, activation=tf.nn.softmax)
])

# Compilando o modelo
model.compile(optimizer=Adam(learning_rate=0.009),
              loss='sparse_categorical_crossentropy',  # Função de
              metrics=['accuracy'])  # Métrica de avaliação
```

Resultados obtidos:

```
Matriz de Confusão:
[[98  0  0]
 [74  0  0]
 [99  0  0]]
              precision    recall  f1-score   support

       clean       0.36      1.00      0.53        98
      litter       1.00      0.00      0.00        74
     recycle       1.00      0.00      0.00        99

    accuracy                           0.36       271
   macro avg       0.79      0.33      0.18       271
weighted avg       0.77      0.36      0.19       271

AUC para classe clean: 0.5037454288073611
AUC para classe litter: 0.4915283303608177
AUC para classe recycle: 0.5035236081747709
```

Relativamente a estes resultados parece que ajustar o número de neurônios não está produzindo melhorias significativas no desempenho do modelo.

Como nas configurações anteriores, o modelo está classificando a maioria das instâncias como "clean", sem conseguir distinguir as classes "litter" e "recycle".

As métricas de precisão, recall e f1-score para as classes "litter" e "recycle" permanecem extremamente baixas, indicando uma incapacidade de aprender corretamente essas classes.

3.6. Dataset menor com modelo de dados MLP (melhor resultado)

O objetivo desta análise é determinar se o desempenho não excelente no conjunto de dados principal está relacionado à complexidade dos dados ou se existem outros fatores a serem considerados na melhoria da implementação do modelo.

O dataset secundário possui imagens mais simples e claras em comparação com o conjunto principal. Isso facilita a análise do código, pois o número de exemplos e classes foi consideravelmente reduzido, permitindo avaliar a eficiência da implementação sem lidar com um grande volume de dados.

Este conjunto menor inclui 1472 fotos, todas com dimensões idênticas. Cada uma das três categorias - maçãs, bananas e cocos - tem cerca de 490 imagens, todas de baixa complexidade.

Maça	Banana	Coco
		

A configuração do modelo MLP usada:

```
# Definindo o modelo da rede neural
model = keras.Sequential([
    keras.layers.Flatten(input_shape=(im_size, im_size, 3)),
    keras.layers.Dense(1024, activation=tf.nn.relu),
    keras.layers.Dense(512, activation=tf.nn.relu),
    keras.layers.Dense(256, activation=tf.nn.relu),
    #keras.layers.Dense(128, activation=tf.nn.relu),
    #keras.layers.Dense(64, activation=tf.nn.relu),
    #keras.layers.Dense(32, activation=tf.nn.relu),
    keras.layers.Dense(3, activation=tf.nn.softmax)
])

# Compilando o modelo
model.compile(optimizer=Adam(learning_rate=0.009),
              loss='sparse_categorical_crossentropy',  # Função d
              metrics=['accuracy'])  # Métrica de avaliação
```

Resultados obtidos:

```
Matriz de Confusão:
[[30  0  0]
 [ 0 24  0]
 [ 0  0 20]]
              precision    recall  f1-score   support

       Apple       1.00      1.00      1.00        30
      Banana       1.00      1.00      1.00        24
       Cocos       1.00      1.00      1.00        20

    accuracy                           1.00        74
   macro avg       1.00      1.00      1.00        74
weighted avg       1.00      1.00      1.00        74

AUC para classe Apple: 1.0
AUC para classe Banana: 1.0
AUC para classe Cocos: 1.0
```

Esta configuração com um dataset mais simples e menor demonstra que o desempenho do modelo está diretamente relacionado à qualidade e complexidade do dataset.

Os resultados desta configuração são muito superiores em comparação com as configurações anteriores. A precisão, recall e f1-score são todos 1.0, indicando um desempenho perfeito.

4. Conclusões

Ao analisar os diferentes testes com variações nas configurações do modelo de MLP, podemos fazer as seguintes conclusões gerais:

Variação nas Camadas: Adicionar mais camadas à rede neural não resultou em melhorias significativas. Na verdade, em alguns casos, houve uma piora no desempenho, indicando possíveis problemas de overfitting.

Variação no Número de Neurônios: Aumentar ou diminuir o número de neurônios também não teve um impacto discernível no desempenho do modelo. Isso sugere que a complexidade da arquitetura da rede não estava diretamente correlacionada com o desempenho.

Variação no Dataset: A configuração com um dataset mais simples e menor mostrou resultados excecionais, com todas as métricas indicando um desempenho perfeito. Isso destaca a importância crítica da qualidade e complexidade do dataset no sucesso do modelo.

Em resumo, o desempenho de um modelo de rede neural está intrinsecamente ligado à qualidade e complexidade do dataset, bem como à seleção adequada de arquitetura e hiperparâmetros e experimentar diferentes configurações e técnicas de melhoria pode levar a um modelo mais eficaz e preciso.

5. Referências

Pesquisas de Dataset's:

-> https://kaggle.com/

-> https://archive.ics.uci.edu/datasets

-> https://paperswithcode.com/datasets

Ferramenta de criação do Dataset:

-> https://chrome.google.com/webstore/search/all image downloader?hl=pt-PT

Bibliotecas:

-> https://scikit-learn.org/stable/

-> https://www.tensorflow.org/

-> https://keras.io/