

INTELIGÊNCIA COMPUTACIONAL - 23/24

Licenciatura em Engenharia Informática, Engenharia Informática – Pós Laboral e Engenharia Informática – Curso Europeu

FASE III - APRENDIZAGEM POR TRANSFERÊNCIA

1. Âmbito

O objetivo desta fase do trabalho consiste na implementação e validação das metodologias de Aprendizagem automática, estudadas no âmbito da disciplina de Inteligência Computacional, a um caso de estudo real, já analisado nas Fase I e II.

Após definir o modelo da uma rede neuronal para o problema (Fase I), estudo de um algoritmo *swarm* para otimização de hiper-parâmetros (Fase II) segue-se a fase de construção do modelo final melhorado recorrendo a transferência de aprendizagem de uma rede CNN ou de “*Large Language Model*”, treinada com grandes conjuntos de dados - imagens ou texto (consoante o problema), e posterior ajuste e **otimização da arquitetura** com base em algoritmos de enxame para pesquisa dos melhores hiper-parâmetros.

2. Desenvolvimento

Nesta Fase III deve executar as seguintes tarefas:

- i) Recolher o conjunto de dados e dividi-lo em treino/validação e teste (20%);
- ii) Ajustar a dimensão e balancear o “dataset” – a técnica de aprendizagem por transferência possibilita a aplicação de modelos complexos a conjuntos de treino mais reduzidos.
- iii) Selecionar uma arquitetura pré-treinada (Figura 1). Para imagem usar redes CNN ou ViT treinadas com grandes datasets, como VGG, ResNet, Xception ou outra à sua escolha. Para texto usar modelos pré-treinados como BERT ou GloVE.
- iv) Definir uma rede densa para as últimas camadas (“top layers”) incluindo a camada de predição.
- v) Recorrendo a um algoritmo do tipo PSO, proceder à **otimização de hiper-parâmetros da rede densa**: Identificar no mínimo dois “hiper-parâmetros” e determinar a melhor configuração com validação cruzada (melhor o trabalho realizado na fase II). Proceder a uma análise comparativa com uma pesquisa em grelha e “random search”.
- vi) Anotar todos os dados num ficheiro excel a apresentar gráficos que permitam visualizar os resultados e analisar a sensibilidade do modelo à variação dos hiper-parâmetros.

- vii) Análise de desempenho final para o conjunto de teste independente com apresentação da matriz de confusão.

O trabalho deve ser desenvolvido com base na linguagem Python e bibliotecas usadas nas aulas, tais como Sklearn, SwarmPackagePy ou Keras.

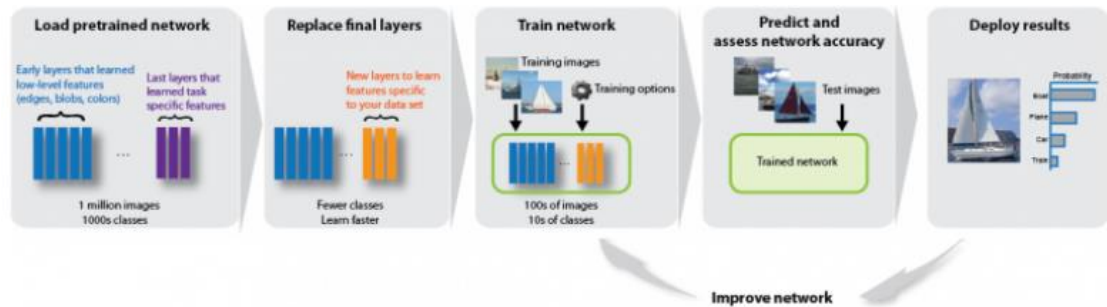


Figura 1. Reutilização de modelos por “Transfer-learning”-
(<https://www.mathworks.com/products/deep-learning.html>)

Após a fase de treino, deverá guardar o modelo, de forma a permitir a verificação posterior do seu desempenho para um conjunto independente de dados.

Prepare o conjunto de treino de forma a ficar balanceado e avalie o impacto do número de instâncias no desempenho dos modelos. A aprendizagem por transferência usualmente permite a obtenção de resultados satisfatórios com um número menor de exemplos de treino. Inclua esta análise nos seus resultados variando a dimensão do treino relativamente ao modelo da fase II.

A entrega do modelo deverá ser acompanhada de código, relatório, ficheiro de resultados (excel) e slides de apresentação.

3. Relatório

O relatório desta fase III, com o máximo de 15 páginas, deve seguir a seguinte estrutura:

- Cap. 1: Descrição do **Problema**;
- Cap. 2: Descrição das **Metodologias** utilizadas;
- Cap. 3: Apresentação da **Arquitetura** de Código – por exemplo diagrama de componentes e diagrama de classes (ou diagrama de fluxo de dados no caso de análise estruturada);
- Cap. 4: Descrição da **Implementação** dos algoritmos;
- Cap. 5: **Análise de Resultados**;
- Cap. 6: **Conclusões**.
- **Bibliografia**

4. Avaliação

A documentação a submeter no Moodle (ficheiro zip) consiste em:

- Relatório (pdf).
- Slides da apresentação (pdf);
- Código;
- Resultados (xls)
- Modelo.

Prazo de entrega: 18 de dezembro de 2023 até às 12h00.

Apresentação e defesa: 18 de dezembro de 2023.

Cotação: 5 valores